强化学习—DQN算法原理详解

2017-11-05 | DQN |

一、 概述

强化学习算法可以分为三大类：value based, policy based 和 actor critic。常见的是以DQN为代表的value based算法，这种算法中只有一个值函数网络，没有policy网络，以及以DDPG,TRPO为代表的actor-critic算法，这种算法中既有值函数网络，又有policy网络。

说到DQN中有值函数网络，这里简单介绍一下强化学习中的一个概念，叫**值函数近似**。在基本概念这篇中有讲过，一个state action pair (s,a)对应一个值函数$Q(s,a)$。理论上对于任意的(s,a)我们都可以由公式求出它的值函数，即用一个查询表lookup table来表示值函数。但是当state或action的个数过多时，分别去求每一个值函数会很慢。因此我们用函数近似的方式去估计值函数：

$$\hat{Q}(s,a,w) \approx Q_\pi(s,a)$$

这样，对于未出现的state action也可以估计值函数。
至于近似函数，DQN中用的是神经网络，当然如果环境比较简单的话用线性函数来近似也是可以的。

DQN算法原文链接： 2013版(arxiv) 2015版(nature)

二、算法原理

在基本概念中有说过，强化学习是一个反复迭代的过程，每一次迭代要解决两个问题：给定一个策略求值函数，和根据值函数来更新策略。

上面说过DQN使用神经网络来近似值函数，即神经网络的输入是state s,输出是$Q(s,a),\forall a \in \mathcal{A}$ (action space)。通过神经网络计算出值函数后，DQN使用$\epsilon-greedy$策略来输出action（第四部分中介绍）。值函数网络与$\epsilon-greedy$策略之间的联系是这样的：首先环境会给出一个obs，智能体根据值函数网络得到关于这个obs的所有$Q(s,a)$，然后利用$\epsilon-greedy$选择action并做出决策，环境接收到此action后会给出一个奖励Rew及下一个obs。这是一个step。此时我们根据Rew去更新值函数网络的参数。接着进入下一个step。如此循环下去，直到我们训练出了一个好的值函数网络。

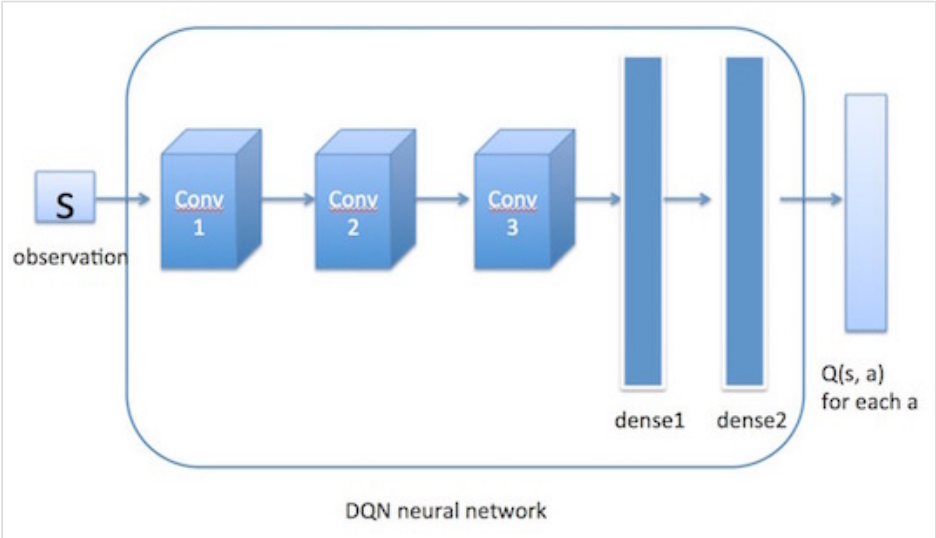

DQN-network

那么每次迭代如何更新神经网络的参数呢?

与机器学习类似，首先会定义一个loss function，然后使用梯度下降GD来更新参数。接下来首先介绍DQN的loss function，它与Q-Learning的非常类似，只是添加了一个target Q function。然后会介绍除此之外，DQN在Q-Learning上所做的改进。

1、Loss Function

$$L(\omega) = E[(R + \gamma \cdot max_{a'} Q(s', a'; \omega^{-}) - Q(s, a; \omega))^2]$$

这个公式表面上看起来很复杂，实际上很好理解，它就是一个残差模型，和我们平常见的最小二乘法很类似，真实值与预测值之间的差的平方。预测值就是$Q(s, a; \omega)$，它是神经网络的输出。“真实值”略微有一点复杂。

想象一下假如我们想求出(s, a)的真实值函数$Q(s, a)$。它表示我从state s开始出发，并采取action a的话，我所能得到的整体收益的期望值。一种可能的情况是，我们知道环境的模型。这在强化学习中也叫Model Based RL。即我们知道状态转移概率矩阵：当处于(s, a)时，下一个到达的状态可能是什么，并且到达每一个状态的概率是什么；我们还知道奖励函数：当处于(s, a)时，得到的立即回报的期望值是什么；另外还知道折扣因子。由此，我们便可以通过贝尔曼方程来求解值函数。这种情况下我们可能也并不需要神经网络近似值函数之类的，直接由策略迭代或值迭代便可以求出最优策略。具体方法可以看一下MDP。

另一种情况就是Model Free RL：不管有没有环境模型，反正我不用。那么在不知道环境模型的情况下如何求解值函数呢？答案就是**采样**。强化学习中有多种采样的方法，这里简单介绍一下：

(1) Monte Carlo

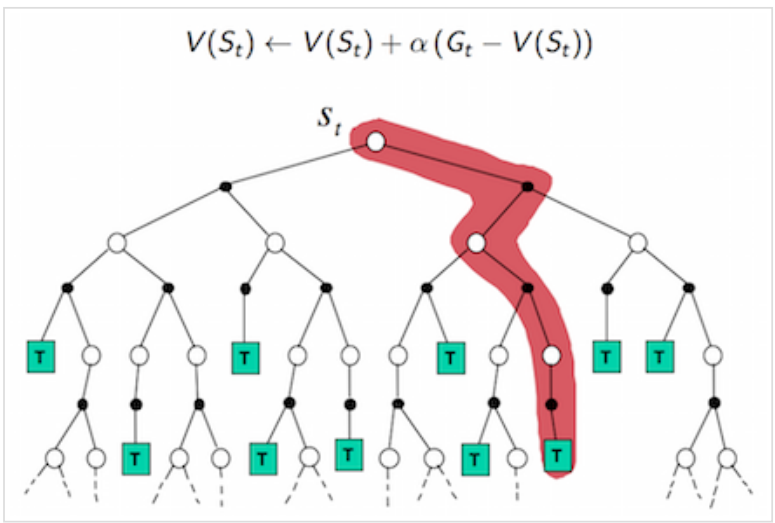

MC

- MC使用一个完整的episode去更新值函数，因此它需要从S_t到Terminal state的完整样本。
- 而且需要等到episode结束才能更新值函数。
- 由于有一条完整的样本，它可以计算出return，而值函数是return的期望，所以我们可以用return去更新值函数。

(2) Temporal Difference / SarSa

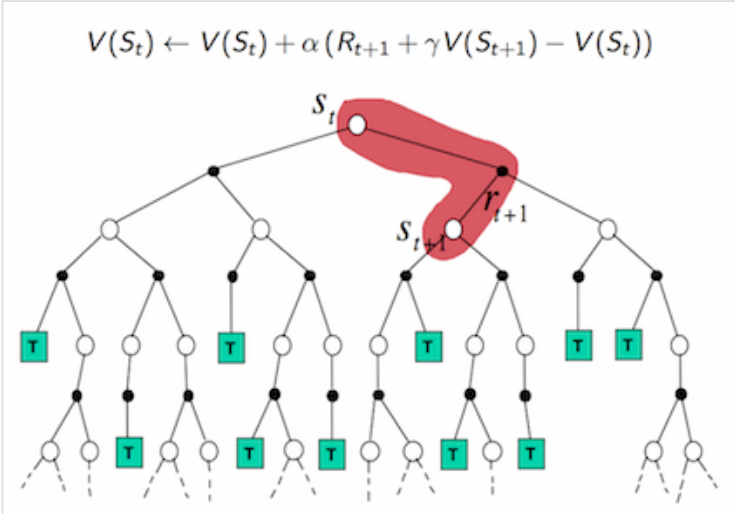

TD

- 与MC不一样的是，TD不需要完整的样本，它只依赖下一个step的值函数，即它用$V(S_{t+1})$ 去更新 $V(S_t)$ (TD), 或用 $Q(S_{t+1}, a_{t+1})$ 去更新 $Q(S_t, a_t)$ (SarSa)
- 它不用等到episode结束，每走一步就可以更新值函数。
- 它不是用的真实的return值来更新值函数，而是用的一个估计值去更新另一个估计值的思想。

另外还有$TD(\lambda)$ (或 $SarSa(\lambda)$)方法，由于DQN中不涉及，暂不介绍。

DQN属于Model Free的强化学习算法，它需要采样。且同SarSa类似，只依赖下一个step的值函数。但它更新值函数的方式与SarSa又有所不同。下面介绍从SarSa到Q-Learning再到DQN的更新值函数的方式。

(1) SarSa

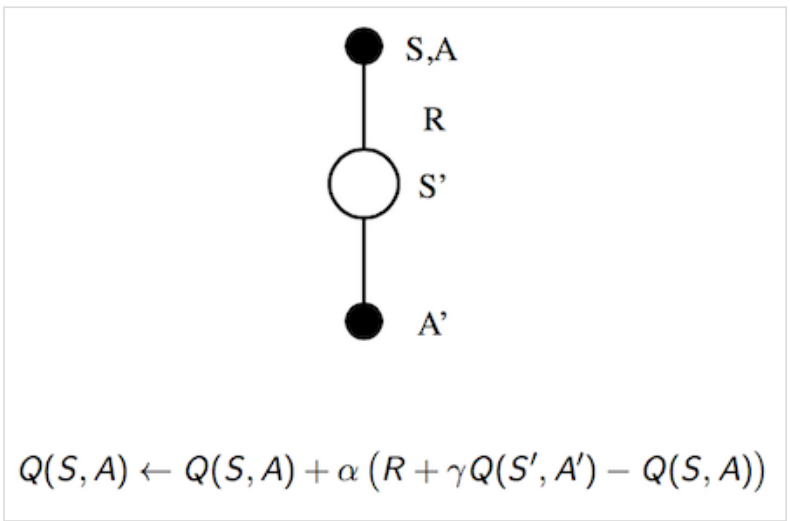

sarsa

SarSa中更新值函数的公式为：

$$Q(s,a) \leftarrow Q(s,a) + \alpha[R + \gamma Q(s',a') - Q(s,a)]$$

也称它的**target**是 $R_{t+1}+\gamma Q(S_{t+1},a_{t+1})$。理解这个target代表的意义：

$$\begin{aligned}V(s)&=E[G_t|S_t=s]\\&=E[R_{t+1}+\gamma G_{t+1}|S_t=s]\\&=E[R_{t+1}+\gamma V(S_{t+1})|S_t=s]\end{aligned}$$

将V换成Q的话我们可以看到，SarSa target $R_{t+1}+\gamma Q(S_{t+1},a_{t+1})$ 是 $Q(S_t,a_t)$ 的估计值。

在值函数近似中，我们都是使用target来替代真实的值函数，即Loss中的真实值。

前面说过DQN是使用$\epsilon-greedy$策略来输出action，SarSa和Q-Learning也是。SarSa中使用$\epsilon-greedy$策略生成action a_{t+1}，随即又用 a_{t+1}处对应的值函数来计算target，更新上一步的值函数。这种学习方式又称为**On-policy**。

SarSa属于On-policy Learning，而Q-Learning属于Off-policy Learning。

(2) Q-Learning

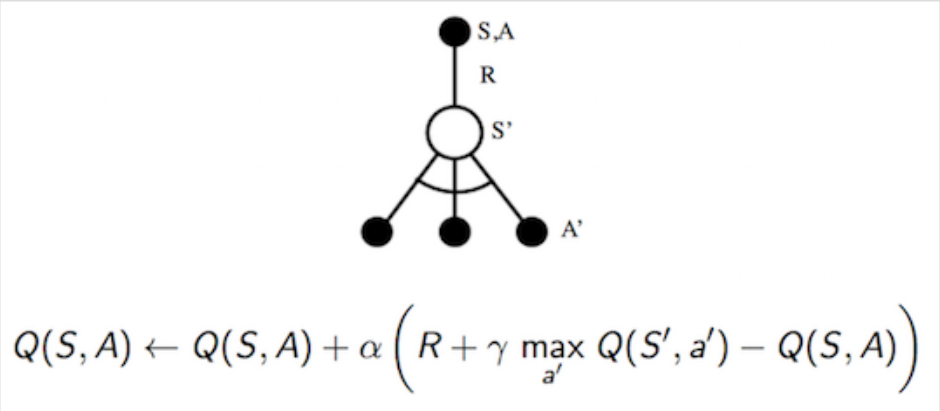

qlearning

Q-Learning的target是 $R_{t+1}+\gamma max_{a'}Q(S_{t+1},a')$。它使用 $\epsilon-greedy$策略来生成action a_{t+1}，但用来计算target的action却不一定是a_{t+1}，而是使得 $Q(S_{t+1},a)$最大的action。这种产生行为的策略和进行评估的策略不一样的方法称为Off-policy方法。对于Q-Learning来说，产生行为的策略是$\epsilon-greedy$，而进行评估的策略是greedy。

(3) DQN

Off-policy是Q-Learning的特点，DQN中也延用了这一特点。而不同的是，Q-Learning中用来计算target和预测值的Q是同一个Q，也就是说使用了相同的神经网络。这样带来的一个问题就是，每次更新神经网络的时候，target也都会更新，这样会容易导致参数不收敛。回忆在有监督学习中，标签label都是固定的，不会随着参数的更新而改变。

因此DQN在原来的Q网络的基础上又引入了一个**target Q网络**，即用来计算target的网络。它和Q网络结构一样，初始的权重也一样，只是Q网络每次迭代都会更新，而target Q网络是每隔一段时间才会更新。DQN的target是 $R_{t+1}+\gamma max_{a'}Q(S_{t+1},a';\omega^-)$。用 ω^-表示它比Q网络的权重 ω更新得要慢一些。

理解了DQN的target之后也就可以理解DQN的Loss Function了。

2、DQN所做的改进

相比于Q-Learning，DQN做的改进：一个是使用了卷积神经网络来逼近行为值函数，一个是使用了target Q network来更新target，还有一个是使用了经验回放Experience replay。

由于在强化学习中，我们得到的观测数据是有序的，step by step的，用这样的数据去更新神经网络的参数会有问题。回忆在有监督学习中，数据之间都是独立的。因此DQN中使用经验回放，即用一个Memory来存储经历过的数据，每次更新参数的时候从Memory中抽取一部分的数据来用于更新，以此来打破数据间的关联。

三、算法整体流程

- 首先初始化Memory D，它的容量为N;
- 初始化Q网络，随机生成权重ω;
- 初始化target Q网络，权重为$\omega^{-} = \omega$;
- 循环遍历episode =1, 2, …, M:
- 初始化initial state S_1;
- 循环遍历step =1,2,…, T:
  - 用$\epsilon - greedy$策略生成action a_t：以ϵ概率选择一个随机的action，或选择$a_t = max_a Q(S_t, a; \omega)$;
  - 执行action a_t，接收reward r_t及新的state S_{t+1};
  - 将transition样本 (S_t, a_t, r_t, S_{t+1})存入D中;
  - 从D中随机抽取一个minibatch的transitions (S_j, a_j, r_j, S_{j+1});
  - 令$y_j = r_j$，如果 $j+1$步是terminal的话，否则，令 $y_j = r_j + \gamma max_{a'} Q(S_{t+1}, a'; \omega^{-})$;
  - 对$(y_j - Q(S_t, a_j; \omega))^2$关于$\omega$使用梯度下降法进行更新;
  - 每隔C steps更新target Q网络，$\omega^{-} = \omega$。
- End For;
- End For.

附上原文的算法流程：

Algorithm 1 Deep Q-learning with Experience Replay

Initialize replay memory $\mathcal{D}$ to capacity N
Initialize action-value function Q with random weights
for episode $= 1, M$ **do**
  Initialise sequence $s_1 = \{x_1\}$ and preprocessed sequenced $\phi_1 = \phi(s_1)$
  for $t = 1, T$ **do**
    With probability ϵ select a random action a_t
    otherwise select $a_t = \max_a Q^*(\phi(s_t), a; \theta)$
    Execute action a_t in emulator and observe reward r_t and image x_{t+1}
    Set $s_{t+1} = s_t, a_t, x_{t+1}$ and preprocess $\phi_{t+1} = \phi(s_{t+1})$
    Store transition $(\phi_t, a_t, r_t, \phi_{t+1})$ in $\mathcal{D}$
    Sample random minibatch of transitions $(\phi_j, a_j, r_j, \phi_{j+1})$ from $\mathcal{D}$
    Set $y_j = \begin{cases} r_j & \text{for terminal } \phi_{j+1} \\ r_j + \gamma \max_{a'} Q(\phi_{j+1}, a'; \theta) & \text{for non-terminal } \phi_{j+1} \end{cases}$
    Perform a gradient descent step on $(y_j - Q(\phi_j, a_j; \theta))^2$ according to equation 3
  end for
end for

dqn

四、$\epsilon - greedy$策略

$greedy$策略，顾名思义，是一种贪婪策略，它每次都选择使得值函数最大的action，即$a_t = max_a Q(S_t, a; \omega)$。但是这种方式有问题，就是对于采样中没有出现过的(state, action) 对，由于没有评估，没有Q值，之后也不会再被采到。

其实这里涉及到了强化学习中一个非常重要的概念，叫Exploration & Exploitation，探索与利用。前者强调发掘环境中的更多信息，并不局限在已知的信息中；后者强调从已知的信息中最大化奖励。而$greedy$策略只注重了后者，没有涉及前者。所以它并不是一个好的策略。

而$\epsilon - greedy$策略兼具了探索与利用，它以ϵ的概率从所有的action中随机抽取一个，以$1-\epsilon$的概率抽取$a_t = max_a Q(S_t, a; \omega)$。

强化学习正是因为有了探索Exploration，才会常常有一些出人意表的现象，才会更加与其他机器学习不同。例如智能体在围棋游戏中走出一些人类经验之外的好棋局。

参考资料：

David Silver的课程：www0.cs.ucl.ac.uk/staff/D.Silver/web/Teaching.html

强化学习

‹ 强化学习-基本概念

强化学习—DDPG算法原理详解 ›